



Extracción Automática de Resultados Electtorales a partir de las Actas de Escrutinio de las Elecciones Generales del Perú 2026

Josemanuel Rossy Cañari Palante, Kenny Asto Hinostroza, Melissa Dessire Aylas Barranca, Carlos Pérez Pérez
Maestría en Inteligencia Artificial — Visión por Computador, Grupo 3
Universidad Nacional de Ingeniería, Lima, Perú

Resumen—Los resultados electorales oficiales del Perú se publican como actas de escrutinio escaneadas, lo que impide su procesamiento automático a gran escala. Presentamos un pipeline de extremo a extremo que descarga las actas del portal oficial de la ONPE, localiza 46 campos por documento mediante una plantilla fija anclada por registro de marcas fiduciales, y lee los conteos manuscritos con OCR restringido a dígitos. La evaluación no necesita anotación manual: la verdad de terreno proviene de los resultados oficialmente digitados que publica el mismo portal, y el conjunto de prueba es una muestra aleatoria nacional con semilla publicada (100 actas, 23 departamentos). La población de actas es heterogénea: el 24 % son documentos nacidos digitales cuya capa de texto rinde 95.1 % de exactitud por campo sin visión alguna. Sobre las 76 actas manuscritas escaneadas (3,268 campos), el pipeline alcanza 59.6 % de exactitud por campo (IC 95 % [56.6, 62.5]) y CER de 0.401, frente a 48.4 % de un LLM multimodal de extremo a extremo con few-shot, cuantificando el techo del reconocimiento genérico y motivando reconocedores afinados con los ~ 43 pares campo–valor que cada acta provee gratuitamente.

Index Terms—análisis de documentos, reconocimiento óptico de caracteres, reconocimiento de dígitos manuscritos, documentos electorales, registro de plantilla

I. INTRODUCCIÓN

Las actas de escrutinio son la fuente oficial de los resultados electorales de cada mesa de sufragio en el Perú. Aunque la Oficina Nacional de Procesos Electorales (ONPE) publica digitalmente todas las actas, la información que contienen es visual: un formulario escaneado donde los miembros de mesa escribieron los conteos de votos a mano. La extracción manual es lenta, propensa a errores y no escala a las $\sim 88,000$ mesas de una elección general, lo que limita la auditoría automática y la verificación independiente.

Este trabajo plantea una pregunta concreta: *¿hasta dónde puede llegar un pipeline clásico de visión por computadora sobre actas peruanas reales muestreadas a escala nacional, y qué implica eso para el diseño de un sistema de producción?* Construimos y evaluamos un pipeline de cinco etapas (adquisición, preprocesamiento, detección de regiones, reconocimiento, salida estructurada) sobre la primera vuelta de las Elecciones Generales 2026. Nuestras contribuciones son:

1. **Un protocolo de evaluación reproducible y sin anotación manual.** El mismo portal que publica la imagen de cada acta publica también sus conteos oficialmente digitados a través de una API interna. Usamos esos valores como verdad de terreno, lo que convierte cada acta descargada en ~ 43 pares campo–valor etiquetados a costo cero, y muestreamos el conjunto de prueba aleatoriamente a escala nacional con semilla publicada.
2. **Detección por plantilla robustecida con registro fiducial.** El acta es un formulario de diseño fijo con marcas de registro impresas. Mostramos que las plantillas de fracciones fijas se rompen ante el encuadre real de los escáneres (bandas negras, desplazamientos) y que un emparejamiento de marcas fiduciales por RANSAC de traslación seguido de una transformación afín parcial recupera la alineación, sumando +8,7 puntos de exactitud.
3. **Un hallazgo poblacional con consecuencias de arquitectura.** En una muestra aleatoria nacional, el 24 % de las actas son documentos nacidos digitales (STAE) cuya capa de texto PDF se puede parsear directamente con 95.1 % de exactitud por campo; solo el 76 % son formularios manuscritos escaneados que requieren visión. Un sistema de producción debe clasificar primero el tipo de acta y enrutar en consecuencia.
4. **Un techo cuantificado para el OCR genérico.** Sobre actas manuscritas, el OCR genérico restringido a dígitos con limpieza cuidadosa de celdas alcanza 59.6 % de exactitud por campo (IC 95 % [56.6, 62.5], bootstrap agrupado). Esto acota lo que puede esperarse sin entrenamiento y motiva el ajuste fino de reconocedores transformer con las etiquetas gratuitas descritas arriba.
5. **Una comparación cara a cara con un LLM multimodal de extremo a extremo.** Bajo un protocolo idéntico, un LLM multimodal actual con few-shot alcanza 48.4 % frente al 60.9 % del pipeline sobre las mismas actas, lo que sitúa su valor en el arranque sin anotación y no en la exactitud de reconocimiento.

El código, los artefactos de evaluación por campo y la

semilla del muestreo son públicos.¹

II. TRABAJOS RELACIONADOS

Detección en tiempo real. RT-DETR [1] mostró que un DETR cuidadosamente diseñado supera a los detectores YOLO de escala comparable (L/X) en exactitud y velocidad, eliminando la supresión de no máximos (NMS) y sus umbrales ajustados a mano. Para actas de escrutinio — tablas de celdas contiguas frecuentemente cubiertas por sellos y firmas — la detección end-to-end sin umbrales es atractiva, y el protocolo de latencia end-to-end de RT-DETR es el que adoptaremos para comparar detectores aprendidos (YOLOv11 vs. RT-DETR) en trabajo futuro. En este artículo la detección se resuelve por registro de plantilla, que a la vez funciona como generador automático de etiquetas para esos detectores.

Reconocimiento de texto. TrOCR [4] estableció el OCR transformer encoder-decoder con modelos de lenguaje pre-entrenados, y DTrOCR [2] mostró que una arquitectura generativa solo-decodificador lo supera en texto impreso, de escena y manuscrito (CER 2.38 en IAM sin modelo de lenguaje externo). Estos resultados justifican los reconocedores transformer como la ruta de mejora para nuestros campos de dígitos manuscritos; una advertencia para nuestro caso es que los priors de lenguaje pueden “corregir” cadenas de dígitos hacia secuencias plausibles, lo que importa al leer números aislados.

Análisis unificado de documentos. OmniParser [3] unifica la localización de texto, la extracción de información clave y el reconocimiento de tablas mediante secuencias de puntos estructurados, y evidencia la debilidad de la generación monolítica de secuencias: Donut [5] colapsa en tablas largas por acumulación de error, cayendo a 22.7 TEDS en PubTabNet frente a 88.83 de OmniParser. Un acta es precisamente una tabla larga más campos clave; la localización explícita de cada valor extraído en OmniParser calza además con el requisito de auditabilidad de los documentos electorales. Mantenemos un pipeline modular — cuyas métricas por etapa son más fáciles de diagnosticar — y tratamos el análisis unificado end-to-end como la alternativa contra la cual comparar.

Ninguno de estos trabajos evalúa dígitos manuscritos en español sobre formularios oficiales con sellos y firmas; esa combinación es la brecha empírica que este proyecto aborda.

III. CONJUNTO DE DATOS

III-A. Fuente y adquisición

Todos los documentos provienen del portal oficial de resultados de la ONPE para las Elecciones Generales 2026 (primera vuelta, 12 de abril de 2026). El portal expone una API interna: buscar una mesa devuelve sus actas y sus estados de procesamiento; el detalle del acta lista sus archivos, donde el tipo 1 es el acta de escrutinio; una URL firmada de S3 sirve el PDF. Las descargas usan impersonación TLS de navegador, una tasa de solicitudes conservadora y un manifiesto reanudable (`src/scrapper/` en nuestro repositorio).

¹https://github.com/carlosperez100/onpe_actas

III-B. Diseño muestral

El universo contiene $\sim 88,064$ códigos de mesa (cota superior hallada por búsqueda exponencial-binaria contra la API). Extrajimos una muestra aleatoria simple sin reemplazo con **semilla publicada (2026)**: 100 actas, 100 % de tasa de acierto, cubriendo 23 prefijos departamentales de *ubigeo* (el código geográfico estándar peruano) con una distribución proporcional al tamaño (Lima concentra el 36 %, consistente con su proporción del electorado). Esto corrige el sesgo del piloto de códigos secuenciales de un solo distrito.

III-C. Heterogeneidad de la población

Clasificar cada PDF por número de páginas y capa de texto revela dos tipos de documento: **76 actas manuscritas** (escaneos de una página, capa de texto vacía) y **24 actas STAE nacidas digitales** (documentos de dos páginas firmados digitalmente, con conteos tipografiados y capa de texto extraíble). La mezcla misma es una estimación muestral: la prevalencia de nacidas digitales es 24 % con intervalo de Wilson al 95 % de [16.7, 33.2] — suficiente para establecer que la población es mixta, no para fijar la proporción exacta. Todos los experimentos de visión corren sobre las 76 manuscritas; las STAE se procesan por parseo directo de texto (Secc. IV-E).

III-D. Verdad de terreno

Para cada mesa muestreada almacenamos los conteos oficialmente digitados que devuelve la API: votos por organización política (38 filas), votos en blanco/nulos/impugnados, totales y electorado. Las posiciones 04 y 14 del formulario corresponden a partidos retirados, están vacías en el formulario y nulas en la API; se excluyen (un empate nulo-con-nulo inflaría espuriamente la exactitud). Esto da **43 campos evaluables por acta, 3,268 en total**.

IV. MÉTODO

IV-A. Visión general del pipeline

(1) *Adquisición*: descarga del PDF más la verdad de terreno oficial. (2) *Preprocesamiento*: rasterización a 300 DPI, enderezamiento por ángulo dominante, normalización de contraste CLAHE, eliminación de ruido non-local means (OpenCV). (3) *Detección de regiones*: plantilla con registro fiducial (abajo). (4) *Reconocimiento*: OCR restringido a dígitos sobre celdas limpias. (5) *Salida estructurada*: un JSON por acta con el esquema de la propuesta.

IV-B. Regiones de plantilla con registro fiducial

El acta es un formulario de diseño fijo, así que 46 regiones (38 celdas de votos como filas equiespaciadas, cuatro filas de resumen, número de mesa, electorado, total de ciudadanos, observaciones) se definen una sola vez como fracciones de página calibradas sobre un acta de referencia (Fig. 1). El muestreo nacional expuso el modo de falla de las fracciones fijas: el encuadre del escáner varía (bandas negras de margen, desplazamientos del contenido de hasta ~ 184 px), corriendo cada celda una fila y produciendo CER > 1 . El propio formulario trae la solución: cuadrados negros de registro impresos en

Figura 1. Acta de referencia con las 46 regiones de la plantilla: 38 celdas de votos (azul), campos de resumen y encabezado (rojo). Las coordenadas de las regiones son fracciones de página, aplicadas tras el registro fiducial.

el borde. Los detectamos como componentes conexos oscuros, cuadrados y de alto relleno dentro de las bandas del borde; emparejamos las marcas detectadas con 15 posiciones de referencia calibradas mediante RANSAC de traslación (cada par detectada-referencia propone un desplazamiento y gana el que deja más inliers), robusto a marcas faltantes y a falsos positivos como los dígitos de muestra impresos; y estimamos una transformación afín parcial que lleva la página al marco de referencia antes de recortar.

IV-C. Reconocimiento de conteos manuscritos

Las celdas se leen con EasyOCR restringido a un vocabulario de dígitos, tras una cascada de limpieza motivada por el análisis de errores de un piloto de 10 actas (Fig. 2): (i) un margen interior elimina los bordes impresos de la celda, que antes se leían como dígitos extra; (ii) la binarización de Otsu por celda aísla la tinta del lapicero y sobrevive a las filas sombreadas alternas del formulario; (iii) los separadores puntuados internos de la celda — tan oscuros como la tinta y por ello inmunes al umbral — se borran *por posición de plantilla* (fracciones fijas del ancho de la celda); (iv) un

Tabla I
ABLACIÓN DEL PILOTO SOBRE 10 ACTAS (430 CAMPOS).

Configuración	Exact. (%)	CER
v1: OCR de dígitos crudo	43.95	0.524
v2: + tinta, bordes, sub-casillas	52.09	0.419
v3: + separadores, Otsu, motas	52.79	0.476
v4: + regla celda-vacía-es-cero	58.37	0.420

filtro de motas por componentes conexos elimina el ruido de digitalización; (v) los campos con casillas impresas por dígito (total de ciudadanos) se leen casilla por casilla. Un respaldo relee el recorte crudo cuando la limpieza vacía trazos tenues.

IV-D. Regla de dominio: celda vacía significa cero

Los miembros de mesa frecuentemente dejan la celda en blanco cuando un partido no recibe votos. Una celda en blanco no es una falla del OCR sino semántica del formulario, así que una regla de post-procesamiento mapea a cero las celdas de partido sin lectura (y los votos impugnados). La reportamos por separado para no acreditarle a la visión un conocimiento de dominio.

IV-E. Enrutamiento de actas nacidas digitales

Las actas STAE se parsean directamente de la capa de texto del PDF: cada nombre de partido va seguido de su conteo tipografiado, y las etiquetas de resumen preceden a sus valores. Emparejar los nombres extraídos con los oficiales por igualdad de cadenas normalizadas produce la exactitud por campo sin ningún procesamiento de imagen.

V. EXPERIMENTOS

V-A. Métricas y protocolo estadístico

Exactitud por campo: coincidencia exacta entre el entero leído y el valor oficial. **CER:** tasa de error por carácter entre las cadenas de dígitos. Los campos de una misma acta comparten escribiente y calidad de escaneo, así que el acta es el clúster estadístico: los intervalos de confianza usan un **bootstrap agrupado** (10,000 remuestreos de actas completas). Todos los artefactos de evaluación (errores por campo, métricas por acta) acompañan al repositorio.

V-B. Ablación del piloto (10 actas, 430 campos)

El piloto — mesas secuenciales de un solo distrito, por tanto sesgado pero útil para el análisis de componentes — cuantifica cada mejora del reconocimiento (Tabla I).

V-C. Evaluación nacional (76 actas manuscritas, 3,268 campos)

La Tabla II muestra el mismo sistema sobre la muestra aleatoria nacional. El registro fiducial (Secc. IV-B) es decisivo: sin él, la variación de encuadre degrada severamente parte de la muestra (peor acta 14 %, CER > 1). El registro suma +8,7 puntos y eleva la peor acta de 14 % a 30 %; la regla de dominio suma +21,6 puntos — a escala nacional, las celdas de cero en blanco son mucho más comunes que en el distrito del piloto.

Tabla II
MUESTRA ALEATORIA NACIONAL, 76 ACTAS MANUSCRITAS (3,268 CAMPOS).

Configuración	Exact. (%)	CER
Plantilla fija, OCR crudo	26.81	0.724
Plantilla fija + regla cero	50.86	0.482
Registrada (v5), OCR crudo	38.00	0.617
Registrada (v5) + regla cero	59.58	0.401

Tabla III
PIPELINE MODULAR VS. LLM FEW-SHOT DE EXTREMO A EXTREMO SOBRE LAS MISMAS 15 ACTAS MANUSCRITAS (645 CAMPOS).

Método	Exact. (%)	CER
Pipeline (plantilla registrada + OCR)	60.93	0.395
LLM few-shot, extremo a extremo (2 ejemplos)	48.37	0.591

Resultado principal. Exactitud por campo **59.58 %**, **IC 95 % [56.61, 62.48]** (± 2.94 puntos); **CER 0.401**, **IC 95 % [0.360, 0.444]**. La exactitud por acta promedia 59.6 % (DE 13.0, rango 30–84 %); la varianza residual proviene de la caligrafía y la calidad de digitalización, ya no de la alineación. La cifra del piloto (58.4 %) resulta cercana, pero solo la estimación nacional tiene un margen de error válido y ofrece cobertura nacional.

Actas nacidas digitales. El parseo por capa de texto de las 24 actas STAE alcanza **95.12 %** (955/1,004 campos); los errores restantes provienen del emparejamiento de nombres, no de la lectura. Veinticuatro actas bastan aquí porque el parseo es determinista: la varianza entre actas está por debajo de la binomial ($ICC \approx 0$, efecto de diseño 1.0), de modo que el intervalo bootstrap agrupado es [94.5, 95.7], nueve veces más estrecho que el de las manuscritas, cuyo efecto de diseño es 3.07 para un número comparable de campos. La brecha de 35.5 puntos (IC 95 % [32.6, 38.5]) cuantifica el valor de enrutar por tipo de documento.

V-D. Línea base con LLM multimodal de extremo a extremo

Una alternativa natural al pipeline modular es entregar la página completa a un LLM multimodal junto con unos pocos ejemplos resueltos, para que localice y lea en un solo paso. Evaluamos esa línea base²: el modelo recibe la imagen completa del acta más dos ejemplos imagen–JSON y debe devolver el JSON de conteos, sin plantilla, sin registro y sin motor OCR. Ambos sistemas se puntúan sobre las mismas 15 actas manuscritas (645 campos) con el mismo protocolo (Tabla III).

El pipeline gana por 12.6 puntos. El LLM interpreta bien la estructura del formulario, pero no está entrenado para dígitos manuscritos peruanos y se degrada más rápido en escaneos de baja calidad: en las dos peores actas cae a 20.9 % y 23.3 % donde el pipeline aún lee 34.9 % y 53.5 %, porque el recorte le entrega al reconocedor una celda aislada mientras que el LLM

debe lidiar con el ruido circundante. Esto es coherente con DTTrOCR [2]: el reconocimiento fuerte de manuscrito proviene del entrenamiento específico, no de la capacidad general. Su ventaja es ortogonal a la exactitud — no requirió ingeniería de detección alguna, mientras que el pipeline necesitó calibrar la plantilla y el registro fiducial —, lo que lo vuelve útil como anotador inicial para un formato nuevo y como pre-etiquetador cuya salida un humano corrige, no como reemplazo de un reconocedor especializado.

V-E. Análisis de errores

Los errores restantes se concentran en: dígitos delgados aislados que la etapa de detección del motor OCR no encuentra; trazos que invaden las franjas borradas de los separadores; confusiones de forma (8 vs. 18, 7 vs. 9) en caligrafías anchas; y campos de casillas múltiples. Son errores de reconocimiento, no de localización — exactamente el componente que el ajuste fino reemplaza.

VI. CONCLUSIONES Y TRABAJO FUTURO

Un pipeline clásico sobre actas peruanas reales muestreadas nacionalmente alcanza 59.6 % de exactitud por campo (IC 95 % [56.6, 62.5]) en documentos manuscritos y 95.1 % en los nacidos digitales, con un protocolo de evaluación que no necesita anotación manual. Destacan tres lecciones de diseño: registrar las plantillas sobre las marcas fiduciales del formulario antes de cualquier recorte por coordenadas fijas; separar la semántica de dominio (blanco = 0) del desempeño de visión; y clasificar el tipo de documento antes de elegir la ruta de procesamiento. Una cuarta lección viene de la línea base con LLM: promptear un modelo multimodal general de extremo a extremo es más barato de construir pero 12.6 puntos menos exacto (48.4 %), de modo que en esta tarea la generalidad aún no sustituye a la especialización. El techo cuantificado del OCR genérico motiva los siguientes pasos: ajustar finamente un reconocedor transformer [2], [4] con los pares campo–valor gratuitos (~ 43 por acta, $\sim 43,000$ con 1,000 actas), entrenar detectores aprendidos (YOLOv11, RT-DETR [1]) con etiquetas autogeneradas por la plantilla registrada, comparar el pipeline modular contra analizadores unificados [3], [5], y usar el LLM como pre-etiquetador en el ciclo de corrección humana que produce el conjunto de ajuste fino.

REFERENCIAS

- [1] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Dang, Y. Liu, and J. Chen, “DETRs beat YOLOs on real-time object detection,” in *Proc. IEEE/CVF CVPR*, 2024, pp. 16965–16974.
- [2] M. Fujitake, “DTTrOCR: Decoder-only transformer for optical character recognition,” in *Proc. IEEE/CVF WACV*, 2024, pp. 8025–8035.
- [3] J. Wan, S. Song, W. Yu, Y. Liu, W. Cheng, F. Huang, X. Bai, C. Yao, and Z. Yang, “OmniParser: A unified framework for text spotting, key information extraction and table recognition,” in *Proc. IEEE/CVF CVPR*, 2024, pp. 15641–15653.
- [4] M. Li, T. Lv, J. Chen, L. Cui, Y. Lu, D. Florencio, C. Zhang, Z. Li, and F. Wei, “TrOCR: Transformer-based optical character recognition with pre-trained models,” in *Proc. AAAI*, 2023, pp. 13094–13102.
- [5] G. Kim, T. Hong, M. Yim, J. Nam, J. Park, J. Yim, W. Hwang, S. Yun, D. Han, and S. Park, “OCR-free document understanding transformer,” in *Proc. ECCV*, 2022, pp. 498–517.

²Gemini 2.5 Flash, capa gratuita, accedido en julio de 2026. Código: `src/recognition/llm_ocr.py`.



Figura 2. Aislamiento de tinta en celdas problemáticas (arriba: recorte; abajo: limpio). Los separadores punteados y bordes impresos — antes leídos como dígitos (p. ej. 18 leído como 418) — se eliminan por umbral, borrado por posición de plantilla y filtrado de motas.